



Pontifícia Universidade Católica de São Paulo

Especialização em Engenharia de Software

Artur Oliveira Santiago

Sistema de Priorização de Escolas em Risco de Evasão: uma ferramenta
preditiva para a gestão da educação estadual de Pernambuco

São Paulo

2026

Artur Oliveira Santiago

Sistema de Priorização de Escolas em Risco de Evasão: uma ferramenta
preditiva para a gestão da educação estadual de Pernambuco

Trabalho de Conclusão de Curso
apresentado à banca examinadora
da Pontifícia Universidade Católica
de São Paulo, como exigência
parcial para obtenção do título de
Especialista em Engenharia de
Software, sob a orientação do prof.
Silvio Luiz Stanzani

Banca Examinadora

À comunidade da Pontifícia
Universidade Católica de São Paulo
pelo apoio permanente.

AGRADECIMENTOS

Ao professor Silvio Luiz Stanzani, meu orientador, agradeço a leitura atenta e as observações precisas que deram forma a este trabalho. Auxiliou para definir o problema e como seguir até a conclusão.

A Raimunda Cláudia, minha companheira, por seu incentivo e apoio sempre que precisei.

À minha família, que sempre tratou o estudo como algo digno de esforço, e aos amigos que acompanharam cada etapa desta especialização.

À Pontifícia Universidade Católica de São Paulo e ao corpo docente da Especialização em Engenharia de Software, pela formação sólida e pelo ambiente de discussão que tornaram este trabalho possível.

Ninguém educa ninguém, ninguém educa a si mesmo, os homens se educam entre si, mediatizados pelo mundo. (FREIRE, 1987, p. 39).

RESUMO

A evasão escolar no Ensino Médio público compromete o desenvolvimento dos jovens e o do país. Em Pernambuco, a taxa média de abandono da rede estadual caiu de 2,05% em 2022 para 0,96% em 2024. Mas a média esconde o problema real: em 2024, dois terços das escolas não registraram nenhum abandono, enquanto 10% delas concentraram 76% dos 2.043 alunos que deixaram a escola. Este trabalho desenvolve um sistema que identifica antecipadamente as escolas de maior risco, adotando a escola, e não o aluno, como unidade de análise. O sistema reúne dados públicos do INEP — Censo Escolar de 2022 a 2024, taxas de rendimento e quatro indicadores complementares — e deriva 39 características por escola. Com elas, estima a taxa de abandono do ano seguinte por árvores impulsionadas por gradiente, comparadas a modelos de referência. A validação impede a mistura de municípios entre treino e teste e respeita a ordem dos anos. Cada previsão é decomposta na contribuição de cada característica, o que mostra quais elevaram ou reduziram o risco daquela escola. O resultado chega ao gestor em um painel que ordena as escolas por risco e explica cada indicação. O sistema acerta a ordem das escolas muito melhor que o valor da taxa: entre as apontadas como prioritárias, cerca de metade está de fato entre as mais críticas, contra 7 em cada 100 na escolha ao acaso. No teste mais exigente, prever um ano que o sistema não viu, uma lista de 150 escolas alcança mais da metade das escolas críticas da rede. Os principais sinais de risco são o histórico recente de abandono, a reprovação e a defasagem entre idade e série. Registra-se ainda uma limitação de equidade: o sistema superestima o risco nas escolas indígenas e quilombolas.

Palavras-chave: Evasão escolar. Priorização de escolas. Aprendizado de máquina. Sistema de apoio à decisão. Engenharia de software. Educação pública.

ABSTRACT

School dropout in Brazilian public high schools compromises both individual and national development. In Pernambuco, the average dropout rate of the state network fell from 2.05% in 2022 to 0.96% in 2024. But the average hides the real problem: in 2024, two thirds of the schools recorded no dropout at all, while 10% of them concentrated 76% of the 2,043 students who left school. This work develops a system that identifies in advance the schools at highest risk, taking the school, not the student, as the unit of analysis. The system gathers public data from INEP — the School Census from 2022 to 2024, performance rates and four complementary indicators — and derives 39 characteristics per school. From these it estimates the dropout rate of the following year with a gradient boosted tree model, compared against baseline models. The validation scheme prevents municipalities from being split across training and test sets and respects the ordering of the years. Each prediction is decomposed into the contribution of every characteristic, showing which ones raised or lowered that school's risk. The result reaches the manager through a dashboard that ranks schools by risk and explains each indication. The system is far better at getting the order of the schools right than the exact value of the rate: of the schools it flags as priorities, about half are in fact among the most critical ones, against 7 out of 100 under random choice. In the most demanding test, predicting a year the system has never seen, a list of 150 schools reaches more than half of the critical schools in the network. Recent dropout history, grade retention and the gap between age and grade are the main risk signals. An equity limitation is also reported: the system overestimates risk in indigenous and quilombola schools.

Keywords: School dropout. School prioritization. Machine learning. Decision support system. Software engineering. Public education.

LISTA DE ILUSTRAÇÕES

Figura 1 – Queda da taxa média da rede e concentração do abandono em 10% das escolas

Figura 2 – Diagrama de casos de uso do sistema

Figura 3 – Diagrama de pacotes

Figura 4 – Diagrama de componentes e fluxo de dados

Figura 5 – Diagrama de atividades do fluxo de execução

Figura 6 – Diagrama de implantação

Figura 7 – Distribuição da taxa de abandono prevista e diferença de risco entre grupos de escolas

Figura 8 – Distribuição das 23 características contínuas na rede estadual

Figura 9 – Repartição das escolas por atributo de sim ou não e taxa média de abandono de cada grupo

Figura 10 – Abandono médio e peso de cada região do estado no conjunto de dados

Figura 11 – As 38 características numéricas ordenadas pela relação com o abandono do ano seguinte

Figura 12 – Distribuição das medidas de desempenho nas 20 repetições

Figura 13 – Desempenho do modelo adotado em cada transição anual (2022→2023 e 2023→2024)

Figura 14 – Resíduo do modelo por escola, em número de alunos que abandonaram o ensino médio, nas transições 2022–2023 e 2023–2024

Figura 15 – Ganho prático da lista de prioridade em relação à escolha ao acaso

Figura 16 – Acerto e alcance da lista para diferentes tamanhos de lista

Figura 17 – Contribuição de cada característica para as previsões do sistema

Figura 18 – Peso e direção de cada característica nas previsões do sistema

Figura 19 – Explicação individual da escola de maior risco previsto

Figura 20 – Erro do sistema por grupo de localização no teste do ano nunca visto

LISTA DE QUADROS

Quadro 1 – Fases do método de desenvolvimento e artefatos produzidos

Quadro 2 – Casamento no tempo entre as características da escola e o abandono previsto

Quadro 3 – Grupos de características usadas pelo sistema

Quadro 4 – Módulos de teste e riscos cobertos

Quadro 5 – Do painel histórico ao conjunto usado na previsão

Quadro 6 – Estatísticas descritivas das 23 características contínuas e relação de cada uma com o abandono do ano seguinte

Quadro 7 – Repartição das escolas por atributo de sim ou não e abandono médio de cada grupo

Quadro 8 – Distribuição das observações e abandono médio por região do estado

Quadro 9 – Desempenho em validação repetida (20 repetições, com faixa de confiança de 95%)

Quadro 10 – Desempenho no teste do ano nunca visto (treino em 2022–2023, teste em 2023–2024)

Quadro 11 – Desempenho do modelo adotado em cada transição anual (média e faixa de confiança de 95% sobre 20 repetições)

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
AFD	Adequação da Formação Docente
CRISP-DM	Cross-Industry Standard Process for Data Mining
EJA	Educação de Jovens e Adultos
EM	Ensino Médio
INEP	Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira
INSE	Indicador de Nível Socioeconômico
IRD	Indicador de Regularidade do Docente
RMSE	Raiz do Erro Quadrático Médio (Root Mean Squared Error)
ROC-AUC	Área sob a Curva ROC (Area Under the ROC Curve)
SHAP	SHapley Additive exPlanations
TCC	Trabalho de Conclusão de Curso
TDI	Taxa de Distorção Idade-Série
XGBoost	Extreme Gradient Boosting

SUMÁRIO

1	Introdução	15
1.1	O Problema da Evasão no Ensino Médio de Pernambuco	15
1.2	Perguntas de Pesquisa	16
1.3	Objetivo Geral	17
1.4	Objetivos Específicos	17
1.5	Escopo do Projeto	17
1.6	Organização do Texto	18
2	Revisão Bibliográfica	19
2.1	Fundamentação Teórica	19
2.1.1	Evasão Escolar: Conceito e Determinantes	19
2.1.2	Mineração de Dados Educacionais	19
2.1.3	Modelos Preditivos Baseados em Árvores	20
2.1.4	Interpretabilidade dos Modelos	20
2.2	Trabalhos Relacionados	20
3	Método de Desenvolvimento	22
3.1	Processo de Desenvolvimento	22
3.2	Fases Executadas	22
3.2.1	Planejamento e Decisões	23
3.2.2	Leitura e Padronização dos Dados do Censo	23
3.2.3	Integração dos Indicadores Complementares	24
3.2.4	Seleção e Preparação das Características	24
3.2.5	Construção e Ajuste do Modelo de Previsão	26
3.2.6	Explicação das Previsões	26
3.2.7	Construção do Painel de Priorização	26
3.2.8	Geração da Lista para um Ano Ainda Não Observado ...	27
3.3	Práticas de Engenharia de Software	28
4	Arquitetura do Software	29
4.1	Aspectos Funcionais e Não-Funcionais	29
4.2	Visão Estrutural	30
4.3	Visão Comportamental	31

4.4 Visão de Implementação e Implantação	33
5 Tecnologias e Aspectos de Implementação	34
5.1 Soluções de Tecnologia	34
5.2 Aspectos de Implementação	34
5.2.1 Estrutura do Código	34
5.2.2 Fluxo dos Dados	34
5.2.3 Painel Interativo	35
5.2.4 Testes Automatizados	35
5.2.5 Gerenciamento de Dependências	35
6 Testes e Análise dos Resultados	36
6.1 Testes de Software	36
6.2 Caracterização dos Dados e Análise das Características Usadas	37
6.2.1 Base Construída	37
6.2.2 O Que o Sistema Prevê	37
6.2.3 Análise Estatística das Características Contínuas	38
6.2.4 Análise Estatística das Características de Sim ou Não ..	42
6.2.5 A Região do Estado	44
6.2.6 Quais Características Têm Valor para a Previsão	45
6.3 Desempenho do Sistema	47
6.3.1 Como o Desempenho Foi Medido	47
6.3.2 Resultados em Validação Repetida	48
6.3.3 Resultados no Teste do Ano Nunca Visto	49
6.3.4 Resultados em Cada Transição Anual	50
6.4 Capacidade de Priorização	52
6.5 Explicação das Indicações	53
6.5.1 Visão Geral	53
6.5.2 Direção dos Efeitos	54
6.5.3 Explicação de Uma Escola	55
6.5.4 Erros do Modelo e Equidade	56
6.6 O Painel de Priorização ao Gestor	57
6.7 Síntese dos Resultados	58
7 Conclusões e Trabalhos Futuros	59
7.1 Conclusões	59
7.2 Trabalhos Futuros	60

Referências	62
Apêndice A – Relação das 39 características usadas pelo sistema	64

1 INTRODUÇÃO

1.1 O Problema da Evasão no Ensino Médio de Pernambuco

A evasão escolar no Ensino Médio compromete o futuro dos jovens e o desenvolvimento do país. No Ensino Médio público brasileiro, o abandono reflete desigualdades sociais, econômicas, geográficas e institucionais profundas. Raramente é um evento isolado: costuma ser o desfecho de um afastamento que se acumula entre o estudante e a escola (BOWERS; SPOTT; TAFF, 2013). Pernambuco implantou um programa pioneiro de Ensino Médio em tempo integral, já avaliado quanto aos efeitos sobre o desempenho dos estudantes (ROSA et al., 2022), e a parcela de matrículas nessa modalidade passou de 56,7% em 2022 para 64,9% em 2024 (BRASIL, 2024a). Mesmo assim a rede segue desigual: as escolas rurais e as do São Francisco Pernambucano reúnem os piores indicadores de infraestrutura, de formação dos professores e de defasagem entre idade e série.


A Secretaria Estadual de Educação de Pernambuco administra cerca de 800 escolas estaduais de Ensino Médio em atividade, distribuídas por 185 municípios (BRASIL, 2024a). Hoje ela não dispõe de um mecanismo que antecipe o risco. Sem ele, o gestor age depois que o abandono já apareceu nos números do ano anterior.

Antecipar esse risco é o que propõe a literatura de mineração de dados educacionais, que aplica técnicas de aprendizado de máquina a dados da educação para prever desfechos como o abandono (BAKER; YACEF, 2009). Estudos dessa linha mostram ser possível estimar o risco a partir de características observáveis das escolas (CORTEZ; SILVA, 2008) e organizá-lo em sistemas de alerta precoce, que priorizam os casos mais críticos (BOWERS; SPOTT; TAFF, 2013). No Brasil, a abordagem já foi aplicada à evasão com dados públicos do INEP (TEODORO; KAPPEL, 2020), e mapeamentos recentes confirmam o crescimento do tema (JESUS; GUSMÃO, 2024; NASCIMENTO et al., 2024).

O ponto de partida deste trabalho é uma constatação sobre o formato do problema. A leitura habitual do abandono é a taxa média da rede, que, segundo as taxas de rendimento do INEP, vem caindo: 2,05% em 2022, 1,37% em 2023 e 0,96% em 2024 (BRASIL, 2024c). Essa leitura sugere que a situação está sob controle e, principalmente, não indica onde agir. O exame ano a ano mostra outro quadro. Em 2024, 2.043 alunos abandonaram o Ensino Médio na rede estadual; 67% das escolas não registraram nenhum abandono, e as 79 escolas mais críticas, 10% da rede, responderam por 76% de todos os alunos que saíram. O problema não está

espalhado pela rede; ele se concentra em poucas escolas. A Figura 1 põe as duas leituras lado a lado.

Figura 1 – Queda da taxa média da rede e concentração do abandono em 10% das escolas



Fonte: elaborado pelo autor.

Essa concentração define o que o sistema precisa fazer. Se o problema estivesse distribuído, bastaria acompanhar a média. Como está concentrado, o valor a entregar é uma lista curta e confiável das escolas do topo, e não uma estimativa precisa da média da rede. Toda a solução descrita neste trabalho decorre desse requisito.

A decisão de prever o risco por escola, e não por aluno, muda a lógica da gestão. Trabalhar em nível de aluno exigiria dados sigilosos e um esforço operacional inviável para uma rede de 800 unidades. Em nível de escola, os dados são públicos, o volume é gerenciável e a decisão do gestor sobre onde alocar equipe, programa e visita acontece nesse mesmo nível.

1.2 Perguntas de Pesquisa

Do recorte apresentado decorrem duas perguntas, que orientam as decisões deste trabalho e às quais o Capítulo 7 responde diretamente.

Pergunta de previsão (P1): é possível identificar antecipadamente quais escolas estaduais de Ensino Médio de Pernambuco terão abandono elevado no ano seguinte, a partir de características observadas no ano corrente?

Pergunta de diagnóstico (P2): quais escolas apresentam abandono significativamente acima ou abaixo do que o seu próprio perfil faria esperar?

As duas se complementam. A primeira define o que o sistema entrega ao gestor: a lista de escolas a priorizar. A segunda olha para as escolas que fogem ao padrão, tanto as que perdem mais alunos do que o perfil indica, e merecem atenção imediata, quanto as que resistem apesar de um perfil desfavorável, e merecem ser estudadas.

1.3 Objetivo Geral

Desenvolver um sistema computacional de identificação precoce do risco de evasão em escolas estaduais de Ensino Médio de Pernambuco, capaz de estimar a taxa de abandono do ano seguinte a partir de características observadas no ano corrente, e de justificar cada indicação de prioridade de forma compreensível para o gestor da Secretaria Estadual de Educação.

1.4 Objetivos Específicos

Os objetivos específicos deste trabalho são:

- a) Construir uma base histórica das escolas estaduais de Ensino Médio de Pernambuco (2022 a 2024) a partir dos dados públicos do Censo Escolar do INEP;
- b) Integrar a essa base quatro indicadores complementares do INEP — nível socioeconômico, regularidade do corpo docente, defasagem idade-série e adequação da formação dos professores —, formando um conjunto único por escola e por ano;
- c) Caracterizar o perfil das escolas e identificar as características associadas ao abandono, com análise estatística de todas as características usadas na previsão;
- d) Definir o conjunto de características da previsão, com regra explícita de casamento no tempo: características do ano corrente para prever o abandono do ano seguinte;
- e) Construir, ajustar e avaliar o modelo de previsão, comparando-o com modelos de referência e com o cenário sem sistema;
- f) Explicar as previsões, indicando quais características elevaram ou reduziram o risco de cada escola;
- g) Entregar as previsões e as explicações em um painel interativo voltado ao gestor da Secretaria Estadual de Educação.

1.5 Escopo do Projeto

O projeto abrange o desenvolvimento completo do sistema, da leitura dos dados públicos à entrega do painel ao gestor, restrito às escolas estaduais de Ensino Médio em atividade em Pernambuco. A unidade de análise é a escola, o que permite trabalhar apenas com dados públicos e mantém o volume em uma faixa gerenciável: cerca de 800 escolas por ano e 1.586 observações no conjunto final.

O escopo técnico compreende cinco frentes: a leitura e a padronização dos dados do Censo Escolar e dos indicadores complementares; a análise e a seleção das

características usadas na previsão; a construção, o ajuste e a avaliação do modelo; a explicação das previsões; e a construção do painel de priorização.

Estão fora do escopo: análises em nível de aluno, dados de redes municipais ou federais, previsões para outros estados e a implantação do sistema no ambiente de produção da Secretaria.

1.6 Organização do Texto

Este trabalho está organizado em sete capítulos. O Capítulo 1 contextualiza o problema, enuncia as perguntas de pesquisa, define os objetivos e delimita o escopo. O Capítulo 2 apresenta a fundamentação teórica e os trabalhos relacionados. O Capítulo 3 descreve o método de desenvolvimento, as fases executadas e as práticas de engenharia de software adotadas. O Capítulo 4 detalha a arquitetura do sistema nas visões funcional, estrutural, comportamental e de implantação. O Capítulo 5 apresenta as tecnologias e os aspectos de implementação. O Capítulo 6 reporta os testes, a análise estatística das características usadas, o desempenho alcançado e a explicação das indicações. O Capítulo 7 responde às perguntas de pesquisa, sintetiza as contribuições e aponta os trabalhos futuros.

2 REVISÃO BIBLIOGRÁFICA

Este capítulo reúne a base conceitual e os trabalhos que sustentam o sistema proposto. A primeira seção estabelece os fundamentos teóricos em quatro frentes: o fenômeno da evasão escolar e seus determinantes, a mineração de dados educacionais como campo que aplica aprendizado de máquina a dados da educação, os modelos preditivos baseados em árvores e as técnicas de interpretabilidade empregadas no trabalho. A segunda seção examina pesquisas correlatas de predição de evasão e situa a contribuição desta monografia diante do que já foi publicado, sobretudo no contexto brasileiro.

2.1 Fundamentação Teórica

2.1.1 Evasão Escolar: Conceito e Determinantes

A evasão escolar é entendida na literatura menos como um evento isolado e mais como o desfecho de um processo prolongado de afastamento entre o estudante e a escola. Bowers, Sprott e Taff (2013) compararam 110 indicadores de risco de abandono reunidos em 36 estudos. Verificaram que os sinais mais precisos são os que acompanham a trajetória do estudante ao longo do tempo, e não os que registram um único momento. O fenômeno é também multinível: além das características do aluno, como desempenho, defasagem idade-série e condição socioeconômica, pesam atributos da própria escola e do território, dimensão que os mapeamentos brasileiros recentes registram entre os fatores indutores mais estudados (JESUS; GUSMÃO, 2024; NASCIMENTO et al., 2024).

No sistema estatístico brasileiro, o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) mede o abandono como a parcela de estudantes que, matriculados no início do ano letivo, deixam de frequentar a escola antes de seu término, distinguindo-o da evasão, associada à não rematrícula no ano seguinte (BRASIL, 2024c). Essa taxa de abandono é o indicador adotado neste trabalho por ser observável anualmente e comparável entre escolas. Para além da mensuração, a permanência escolar tem valor formativo e social: Freire (1987) situa a educação como prática de emancipação, o que confere ao enfrentamento da evasão um significado que ultrapassa o desempenho estatístico da rede.

2.1.2 Mineração de Dados Educacionais

A aplicação sistemática de técnicas computacionais a dados educacionais consolidou-se no campo da mineração de dados educacionais (educational data mining). Baker e Yacef (2009), ao revisarem o estado do campo, organizam seus

métodos em cinco categorias: predição, agrupamento, mineração de relações, destilação de dados para julgamento humano e descoberta com modelos. Situam a predição entre as tarefas centrais da área — estimar um resultado futuro, como desempenho ou abandono, a partir de atributos observados. Um exemplo precursor é o de Cortez e Silva (2008), que empregaram árvores de decisão, florestas aleatórias, redes neurais e máquinas de vetores de suporte para prever o desempenho de estudantes do ensino secundário português.

2.1.3 Modelos Preditivos Baseados em Árvores

Entre os métodos de aprendizado de máquina, os baseados em árvores de decisão destacam-se no tratamento de dados tabulares, como os deste trabalho. Breiman (2001) propôs as florestas aleatórias (random forests), que combinam um grande número de árvores treinadas sobre amostras e subconjuntos de atributos distintos, reduzindo a variância e a tendência ao sobreajuste de uma árvore isolada. Uma alternativa que costuma alcançar desempenho superior em dados tabulares é o gradiente impulsionado (gradient boosting), no qual as árvores são construídas em sequência, cada uma corrigindo os erros das anteriores. Chen e Guestrin (2016) apresentaram o XGBoost, uma implementação escalável e regularizada desse princípio, amplamente adotada por seu desempenho e eficiência, e escolhida como modelo principal desta monografia.

2.1.4 Interpretabilidade dos Modelos

Modelos de alto desempenho como as florestas e o gradiente impulsionado são frequentemente descritos como caixas-pretas, pois a relação entre suas entradas e saídas não é diretamente legível. Em decisões de interesse público, saber por que uma previsão foi feita é tão importante quanto a previsão. Duas técnicas tornaram-se referência para explicar previsões de qualquer modelo. O LIME, de Ribeiro, Singh e Guestrin (2016), aproxima localmente o modelo por um substituto interpretável; seus autores situam a explicação como condição para que se possa confiar tanto em uma previsão isolada quanto no modelo que a produz. O SHAP, de Lundberg e Lee (2017), atribui a cada atributo uma contribuição para a previsão com base na teoria dos valores de Shapley, o que dá explicações consistentes no nível individual e no global. Este trabalho adota o SHAP para explicar o risco previsto de cada escola.

2.2 Trabalhos Relacionados

A predição de evasão por aprendizado de máquina é um tema ativo, inclusive no Brasil. Dois mapeamentos sistemáticos recentes ilustram a produção nacional: Jesus

e Gusmão (2024) recuperaram 336 estudos e analisaram os 71 que atenderam aos critérios de inclusão, e Nascimento et al. (2024) revisaram as técnicas de mineração de dados aplicadas à evasão estudantil. Ambos apontam o predomínio das abordagens de classificação e a concentração de trabalhos no ensino superior. Teodoro e Kappel (2020) aplicaram cinco técnicas de aprendizado de máquina a dados públicos do Inep para prever o risco de evasão em instituições públicas de ensino superior — exemplo próximo desta monografia quanto à fonte de dados, ainda que voltado a outro nível de ensino.

No campo dos sistemas de alerta precoce (early warning systems), o mesmo estudo de Bowers, Sprott e Taff (2013) mostrou, por análise ROC, que muitos indicadores usuais têm alta precisão mas baixa acurácia, e que os mais confiáveis se apoiam em desempenho e trajetória. Isso justifica avaliar um sistema de priorização não apenas pelo erro médio, mas pela capacidade de ordenar corretamente as escolas de maior risco — critério adotado neste trabalho. Resta uma lacuna: a maior parte da literatura opera no nível do estudante e no ensino superior. Esta monografia toma a escola como unidade de análise na educação básica, combinando dados públicos, um modelo de gradiente impulsionado e explicações por SHAP para apoiar a priorização de intervenções pela gestão estadual.

3 MÉTODO DE DESENVOLVIMENTO

3.1 Processo de Desenvolvimento

O sistema é um encadeamento automatizado de etapas que vai da leitura dos dados públicos do INEP até a lista de escolas prioritárias entregue ao gestor. O desenvolvimento combinou um ciclo iterativo e incremental com o processo CRISP-DM (CHAPMAN et al., 2000), que organiza projetos desse tipo em seis etapas: entendimento do negócio, entendimento dos dados, preparação dos dados, construção do modelo, avaliação e implantação. Cada fase produz artefatos verificáveis antes de a seguinte começar: código coberto por testes, dados intermediários gravados em disco e um relatório técnico.

Duas decisões de organização atravessam todas as fases. A primeira separa o código de produção, formado pelos módulos reaproveitáveis do sistema, do código de análise, que apenas os consome para gerar relatórios e figuras. A segunda faz os dados percorrerem três estágios sucessivos, dos arquivos originais aos intermediários e destes ao conjunto final, sem que um estágio jamais sobrescreva o anterior. Juntas, sustentam duas propriedades exigidas do sistema: qualquer resultado pode ser feito a partir dos arquivos originais, e cada módulo pode ser testado isoladamente. A estrutura concreta que materializa essas decisões está no Capítulo 5.

3.2 Fases Executadas

O Quadro 1 resume as fases do método, os artefatos produzidos e a situação de cada uma.

Quadro 1 – Fases do método de desenvolvimento e artefatos produzidos

Fase	Etapas do processo	Principais artefatos
0. Planejamento e decisões	Entendimento do negócio	Documento de decisões: perguntas, unidade de análise, indicador a prever, fontes de dados e tecnologias
1. Leitura e padronização do Censo	Entendimento e preparação dos dados	Módulos de carga, filtro e montagem da base; base histórica com 2.392 registros e 806 escolas; dez análises descritivas
2. Integração dos indicadores	Preparação dos dados	Um módulo de leitura por indicador; arquivos intermediários padronizados por escola e ano
3. Seleção e preparação das características	Preparação dos dados	Módulo de construção do conjunto final: 1.586 observações e 39 características, sem lacunas; análise

		estatística de todas elas
4. Construção e ajuste do modelo	Construção do modelo	Módulos de treino e avaliação; modelos de referência e modelo principal; busca de configuração; modelos gravados em disco
5. Explicação das previsões	Avaliação	Módulo de explicação; contribuição de cada característica por escola; análise dos erros por grupo
6. Painel de priorização	Implantação	Camada de serviço testável e aplicação web com lista de risco, detalhe por escola e diagnóstico
7. Geração da lista para novos anos	Implantação	Modo de predição para um ano ainda não observado; ranking de risco gravado em disco; validação das fontes do ano solicitado

Fonte: elaborado pelo autor.

3.2.1 Planejamento e Decisões

A fase inicial consolidou as decisões estruturantes. A escola, e não o aluno, foi definida como unidade de análise, por três razões: os dados públicos existem nesse nível, o gestor decide nesse nível e o volume resultante é adequado a um sistema que precisa ser auditável. O universo foi delimitado às escolas estaduais em atividade com Ensino Médio regular em Pernambuco. Definiram-se ainda as fontes de dados e as tecnologias, descritas no Capítulo 5.

3.2.2 Leitura e Padronização dos Dados do Censo

A primeira fase de implementação construiu a leitura dos microdados do Censo Escolar (BRASIL, 2024a). Um módulo carrega os arquivos anuais com busca tolerante pelos nomes das colunas, já que o INEP muda a nomenclatura entre edições. Outro aplica, em sequência auditável, os filtros de estado, rede estadual, escola em atividade e oferta de Ensino Médio. Um terceiro empilha os três anos em uma base histórica por escola e ano. O resultado é estável: 2.392 registros, 806 escolas, 97,4% delas presentes nos três anos.

Dez análises descritivas caracterizaram o universo, cobrindo abrangência municipal, porte das escolas, infraestrutura e oferta de tempo integral; seus resultados estão reunidos no Capítulo 6. Um deles já orienta a leitura do restante: o índice de infraestrutura é muito menor nas escolas rurais do que nas urbanas (0,52 contra 0,71). Essa fase também revelou problemas nos dados de origem que orientaram decisões posteriores: uma coluna de matrículas ausente em todo o ano de 2022,

que foi descartada, e o código de região do estado, que muda de formato entre 2022 e 2023 e precisou ser convertido.

3.2.3 Integração dos Indicadores Complementares

A segunda fase incorporou cinco fontes complementares do INEP: as taxas de rendimento, que reúnem aprovação, reprovação e abandono, no total e por série (BRASIL, 2024c), e quatro indicadores educacionais — o nível socioeconômico, a regularidade do corpo docente, a defasagem idade-série e a adequação da formação dos professores (BRASIL, 2024b).

As taxas de rendimento exigiram tratamento específico: vêm em planilhas com oito linhas de cabeçalho e uma marca própria para “escola não oferece a série”, que precisa ser convertida em ausência, nunca em zero. Confundir as duas coisas distorceria todas as médias da rede.

Dois indicadores adicionais foram lidos e avaliados: o esforço docente e a complexidade de gestão. Eles não foram incorporados, porque a informação que trazem já estava contida nas colunas existentes. A avaliação está no Capítulo 6.

3.2.4 Seleção e Preparação das Características

A terceira fase construiu o conjunto usado na previsão e fixou a regra de casamento no tempo: as características de um ano são associadas ao abandono do ano seguinte. O ano de 2024 não entra como ano de origem porque exigiria o rendimento de 2025, ainda inexistente. O Quadro 2 mostra a regra e o papel de cada par de anos.

Quadro 2 – Casamento no tempo entre as características da escola e o abandono previsto

Características da escola (ano corrente)	Abandono previsto (ano seguinte)	Uso no projeto
Censo e indicadores de 2022	Abandono de 2023	Treino do modelo
Censo e indicadores de 2023	Abandono de 2024	Teste em ano nunca visto
Censo e indicadores de 2024	Abandono de 2025	Lista entregue ao gestor

Fonte: elaborado pelo autor.

O Censo Escolar traz mais de 400 características por escola, e o sistema usa 39. A redução é deliberada: com 1.586 observações, manter centenas de colunas faria o sistema decorar a base em vez de aprender o padrão, de modo que ele acertaria o passado e erraria o ano seguinte (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). O Quadro 3 agrupa as características mantidas.

Quadro 3 – Grupos de características usadas pelo sistema

Grupo de características	Colunas	O que descreve
Contexto e localização	4	Zona urbana ou rural, localização diferenciada (indígena ou quilombola) e região do estado, oferta de EM fora das séries regulares
Porte e proporções	5	Matrículas no Ensino Médio, alunos por turma, alunos por professor, computadores por aluno e proporção de alunos em tempo integral
Infraestrutura	13	Água potável, esgoto, biblioteca, laboratórios, quadra, refeitório, sala de leitura, auditório, internet e um índice-resumo
Corpo docente	4	Regularidade do corpo docente e adequação da formação dos professores em três faixas
Perfil dos alunos	5	Nível socioeconômico médio da escola e defasagem idade-série, no total e por série
Histórico de rendimento	8	Taxas de abandono e de reprovação do próprio ano, no total e por série
Total	39	—

Fonte: elaborado pelo autor.

Três critérios guiaram os cortes, alinhados às diretrizes de seleção de variáveis da literatura (GUYON; ELISSEFF, 2003). Saiu, primeiro, a informação repetida: o número de turmas e o de professores acompanham quase perfeitamente o de matrículas, e manter os três apenas confunde o sistema. Saiu também o que é consequência aritmética de outra coluna, como a taxa de aprovação, que é o que sobra depois da reprovação e do abandono; fornecê-la seria entregar a resposta antecipadamente. Saíram, por fim, as colunas ausentes na maior parte das escolas, caso das taxas de séries oferecidas por poucas unidades. As ausências restantes foram preenchidas pela média das escolas da mesma região no mesmo ano, e o conjunto final não tem lacunas.

A análise estatística de cada uma das 39 características, que sustenta esses critérios e responde quais delas têm de fato valor para a previsão, está no Capítulo 6.

3.2.5 Construção e Ajuste do Modelo de Previsão

A quarta fase construiu o modelo. Antes do modelo principal foram avaliados dois modelos de referência, um linear (regressão Ridge) e um baseado em árvores de decisão (floresta aleatória), além do piso trivial, que responde sempre a média da rede. Sem essa comparação não haveria como afirmar que o sistema agrega valor.

O preparo das características é o mesmo para todos os modelos: preenchimento das ausências, padronização de escala e conversão da região do estado em indicadores próprios. Só com o preparo idêntico a comparação é justa.

O modelo principal teve sua configuração escolhida por busca sistemática, avaliando 48 combinações sob o mesmo protocolo de validação. A configuração vencedora é deliberadamente contida: cada regra interna considera poucas condições por vez, o aprendizado avança em passos pequenos e a complexidade é penalizada. Em uma base de treino de menos de 800 observações, é essa contenção que impede o sistema de decorar as escolas que já viu, em vez de aprender o padrão que vale para as demais. O modelo final é gravado em disco e carregado pelo painel; treino e uso são etapas separadas.

3.2.6 Explicação das Previsões

A quinta fase tornou cada previsão explicável. Sobre o modelo gravado monta-se um explicador que decompõe a previsão de cada escola na contribuição de cada característica, com magnitude e direção. A mesma fase produziu a análise dos erros do modelo por grupo de escolas, que revelou um viés relevante, discutido no Capítulo 6. Um teste automatizado verifica a consistência da decomposição: a soma das contribuições precisa reproduzir a previsão.

3.2.7 Construção do Painel de Priorização

A sexta fase entregou o painel. A regra de negócio ficou isolada em uma camada própria: um módulo carrega o modelo e as características, calcula a lista de risco do ano, gera a explicação de cada escola e classifica os erros em alerta ou resiliência; outro traduz os nomes técnicos das colunas para linguagem de gestor. A interface apenas apresenta esses resultados. Essa separação segue o mesmo princípio das demais camadas: a regra é testável sem a tela.

O painel foi definido como ferramenta de apoio à decisão, que prioriza escolas e explica o porquê, e não como recomendação automática de ações. A razão é metodológica: o sistema identifica associações, não causas, e a literatura de validação alerta justamente para o risco de modelos que se apoiam em preditores

não causais (ROBERTS et al., 2017). Sugerir a intervenção específica exigiria evidência de causalidade que os dados não sustentam. O painel mostra onde olhar primeiro e por quê; a decisão de como agir permanece com o gestor.

3.2.8 Geração da Lista para um Ano Ainda Não Observado

A sétima fase tornou o sistema utilizável a cada nova edição dos dados. O modelo não é ajustado a um par de anos específico: ele aprende uma relação geral entre as características da escola em um ano e o abandono do ano seguinte. Essa propriedade permite gerar uma lista nova sempre que o INEP publica uma edição, e é o papel da terceira linha do Quadro 2, em que as características de 2024 servem para prever o abandono de 2025.

A dificuldade é que o conjunto usado no treino só admite escolas cujo abandono do ano seguinte já foi observado, e esse valor ainda não existe no ano que se quer prever. A construção das características ganhou então um modo que dispensa a exigência do alvo, mantendo todo o resto idêntico ao do treino: as mesmas colunas, na mesma ordem, com a mesma imputação de ausências. Antes de qualquer cálculo, o módulo verifica se as fontes do ano solicitado já foram carregadas; se faltar alguma, interrompe a execução com uma mensagem que diz qual ano importar. Falhar de forma explícita é preferível a produzir uma lista silenciosamente incompleta.

Sobre esse conjunto, um módulo próprio carrega o modelo gravado em disco e devolve as escolas ordenadas por risco, com a posição de cada uma, o ano de referência e o ano previsto. O resultado é gravado em disco e pode ser acionado por uma única linha de comando, informando o ano de referência. Treino e uso permanecem separados: gerar a lista de um ano novo não exige treinar o modelo outra vez. Com os dados já disponíveis, a lista de 2025 foi gerada a partir das características de 2024 e cobre as 791 escolas da rede, com risco médio previsto de 0,85%. Essas previsões são inteiramente fora da amostra: o modelo nunca viu o ano que está prevendo.

Quatro verificações automatizadas protegem esse caminho, porque um erro aqui não geraria sintoma: as características de predição têm de ser idênticas às do treino, o conjunto tem de conter apenas o ano solicitado, não pode restar nenhuma ausência e a lista devolvida tem de estar íntegra. Uma quinta verifica que o pedido de um ano sem dados falha com a mensagem correta.

3.3 Práticas de Engenharia de Software

Ao longo de todas as fases foram aplicadas práticas que sustentam a qualidade e a reprodutibilidade do sistema:


- a) Arquitetura em camadas: o código de produção é organizado em pacotes de responsabilidade única, com dependências em sentido único e sem ciclos. Cada camada pode ser testada e reexecutada isoladamente;
- b) Testes automatizados: a suíte tem 138 testes e roda por inteiro a cada alteração. Ela cobre os filtros do universo, a integridade da base histórica, a leitura das planilhas do INEP, o casamento no tempo entre as características e o abandono, a ausência de vazamento entre treino e teste, a consistência das explicações, a ordenação da lista e a equivalência entre as características de treino e as de predição;
- c) Configuração centralizada: caminhos, anos de referência e constantes ficam em um único módulo, o que elimina duplicação e facilita executar o sistema em outro ambiente;
- d) Reprodutibilidade: o ambiente é isolado e as versões das bibliotecas são fixadas. Os dados intermediários são gravados em disco, o que permite retomar qualquer etapa.

4 ARQUITETURA DO SOFTWARE

4.1 Aspectos Funcionais e Não-Funcionais

Os requisitos funcionais decorrem diretamente do usuário-alvo, o gestor da Secretaria. O caso de uso central é consultar a lista de risco das escolas para o ano seguinte. A ele somam-se consultar a explicação individual de cada escola e inspecionar o diagnóstico que sinaliza escolas cujo abandono observado diverge do previsto pelo seu perfil. Um segundo ator, o analista responsável pela manutenção, responde por executar o fluxo de dados e por treinar ou atualizar o modelo. O INEP figura como ator de apoio, fornecedor dos dados. A Figura 2 reúne esses atores e casos de uso.

Figura 2 – Diagrama de casos de uso do sistema



Fonte: elaborado pelo autor.


Cinco requisitos não funcionais orientaram o projeto. A reprodutibilidade exige que qualquer resultado possa ser reconstruído a partir dos dados originais, que permanecem imutáveis. A explicabilidade obriga o sistema a justificar cada indicação de prioridade, o que restringe a escolha às soluções cujas previsões possam ser decompostas e apresentadas ao gestor. A ausência de vazamento pede que a validação respeite a ordem do tempo e a proximidade geográfica: o sistema nunca pode ser avaliado com informação que não teria no momento do uso, sob pena de produzir números otimistas e falsos. A testabilidade cobre cada módulo com testes

automatizados. E a portabilidade requer que a aplicação seja empacotável para implantação, sem depender da máquina de desenvolvimento.

4.2 Visão Estrutural

A visão estrutural é apresentada em dois níveis. No nível do código-fonte, o diagrama de pacotes mostra dependências em sentido único e sem ciclos, ou seja, nenhuma camada depende, direta ou indiretamente, de outra que dependa dela: a camada de características depende da camada de dados; a de modelo, da de características; a do painel, da de modelo. A configuração é transversal a todas. Os scripts de análise e os testes consomem as camadas de produção, e nenhuma camada de produção depende deles. É essa orientação acíclica, representada na Figura 3, que permite testar e reexecutar cada camada isoladamente.

Figura 3 – Diagrama de pacotes




Fonte: elaborado pelo autor.

No nível de execução, o diagrama de componentes mostra o fluxo que os conecta. O componente de leitura consome os dados originais do INEP e grava produtos intermediários padronizados. O componente de preparação os consome e materializa o conjunto final. O componente de modelo treina, avalia e grava o modelo. Os componentes de explicação e de painel carregam o modelo gravado. A

comunicação entre componentes se dá sempre por arquivos em disco, e não por chamadas diretas. O acoplamento é fraco: nenhum componente precisa que o outro esteja em execução, o que permite retomar o fluxo a partir de qualquer etapa. A Figura 4 mostra esses componentes e o caminho percorrido pelos dados.

Figura 4 – Diagrama de componentes e fluxo de dados

Figura - Diagrama de componentes e fluxo de dados




Fonte: elaborado pelo autor.

4.3 Visão Comportamental

A visão comportamental descreve a ordem de execução, da aquisição dos dados à entrega da lista. O fluxo é essencialmente sequencial, refletindo as dependências entre as etapas: a carga precede a filtragem; a filtragem precede a montagem da base histórica; sobre ela integram-se os indicadores complementares; em seguida constroem-se as características do ano corrente associadas ao abandono do ano seguinte; a etapa de modelo treina, avalia e grava; a de explicação decompõe as previsões; e a final serve a lista ao gestor. Cada atividade corresponde a um módulo testável e termina produzindo um artefato verificável. A Figura 5 detalha essa sequência.

Figura 5 – Diagrama de atividades do fluxo de execução


Figura - Diagrama de atividades do pipeline

Fonte: elaborado pelo autor.

4.4 Visão de Implementação e Implantação

No ambiente atual, todo o sistema executa em uma única estação de desenvolvimento, sobre um ambiente isolado. Os dados, nos três estágios, e os modelos gravados ficam no sistema de arquivos local. O painel já roda como aplicação web local, acessada pelo navegador. Para a implantação definitiva, prevê-se empacotar a aplicação e o modelo em contêiner, o que elimina a dependência da máquina de desenvolvimento e atende ao requisito de portabilidade. A separação entre o ambiente de treino, que produz o modelo, e o de execução, que apenas o carrega, é deliberada: permite atualizar o modelo sem tocar na aplicação, e vice-versa. A Figura 6 representa esse arranjo.

Figura 6 – Diagrama de implantação



Fonte: elaborado pelo autor.

5 TECNOLOGIAS E ASPECTOS DE IMPLEMENTAÇÃO

5.1 Soluções de Tecnologia

A linguagem base é o Python, escolhida pela maturidade do ecossistema de bibliotecas necessárias ao projeto. O tratamento e a limpeza dos dados usam as bibliotecas pandas (McKINNEY, 2010) e NumPy (HARRIS et al., 2020); a leitura das planilhas do INEP usa o openpyxl.

A construção do modelo usa o scikit-learn (PEDREGOSA et al., 2011) e o XGBoost (CHEN; GUESTRIN, 2016). Do scikit-learn vêm o preparo das características, os modelos de referência, a busca de configuração e os protocolos de validação; do XGBoost, o modelo principal. Os modelos treinados são gravados em disco com o joblib.

A explicação das previsões usa a biblioteca SHAP (LUNDBERG; LEE, 2017), otimizada para modelos baseados em árvores. As figuras são geradas com matplotlib. O painel usa Streamlit para a interface e plotly para os gráficos. Os dados intermediários são gravados em Parquet, formato compacto e de leitura rápida.

A qualidade do código é sustentada pelo pytest, que executa a suíte de testes. As versões das dependências ficam fixadas em um arquivo próprio, dentro de um ambiente isolado.

5.2 Aspectos de Implementação

5.2.1 Estrutura do Código

A separação entre código de produção e código de análise, estabelecida no Capítulo 3, materializa-se em diretórios. Os módulos reaproveitáveis ficam no pacote src, em quatro camadas: aquisição e preparação de dados (src.data), construção das características usadas na previsão (src.features), modelo e explicação (src.models) e serviço do painel (src.recommend). Uma camada transversal de configuração centraliza caminhos e constantes. Os scripts de análise, numerados na ordem em que devem ser executados, ficam em notebooks; a aplicação do painel, em app; e os testes, em tests.

5.2.2 Fluxo dos Dados

Os três estágios de dados também correspondem a diretórios distintos: os arquivos originais do INEP, que permanecem imutáveis; os arquivos intermediários, um por fonte, já padronizados por escola e ano; e o conjunto final usado na previsão. Cada etapa lê o artefato da etapa anterior e grava o seu em disco, no formato Parquet.

Como nenhuma etapa aciona a seguinte diretamente, é possível reexecutar apenas o trecho afetado por uma correção, sem repetir o fluxo inteiro.

5.2.3 Painel Interativo

No painel, essa mesma disciplina se traduz em três partes. A camada de serviço concentra a regra de negócio: lista de risco, explicação por escola e diagnóstico. Um módulo à parte traduz os nomes técnicos das colunas para a linguagem do gestor. A interface apenas consome essas duas partes. O modelo e o conjunto de características são carregados uma única vez, quando a aplicação sobe, e as explicações de todas as escolas são calculadas nesse momento, de modo que a navegação entre filtros e abas não repete o cálculo. Como a regra vive fora da tela, ela é testada sem que a interface precise ser executada.

5.2.4 Testes Automatizados

A suíte é executada pelo pytest e organizada em um módulo por camada. Os testes constroem os próprios dados sintéticos, pequenos e escritos no corpo de cada caso, de modo que nenhuma execução depende dos microdados do INEP — que são grandes e podem não estar disponíveis em outra máquina. Os riscos cobertos por cada módulo estão detalhados no Capítulo 6.

5.2.5 Gerenciamento de Dependências

Todas as bibliotecas usadas são declaradas com versão mínima em um único arquivo de dependências, instalado em um ambiente isolado. Isso garante que o sistema possa ser reconstruído em outra máquina com o mesmo comportamento, atendendo ao requisito de reprodutibilidade estabelecido na arquitetura.

6 TESTES E ANÁLISE DOS RESULTADOS

6.1 Testes de Software

A corretude do sistema é garantida por uma suíte de 138 testes automatizados, que roda por inteiro a cada alteração; todos passam na última execução. Mais do que a quantidade, importa o tipo de risco que eles cobrem. Em sistemas que aprendem a partir de dados, os erros de preparação em geral não interrompem a execução: produzem, em silêncio, um modelo inválido que continua respondendo normalmente, risco já documentado como característico de sistemas de aprendizado de máquina em produção (SCULLEY et al., 2015). Um deslocamento de um ano no casamento entre as características e o abandono, por exemplo, destruiria todo o valor preditivo sem gerar qualquer sintoma. Por isso os testes se concentram nos riscos que comprometeriam a validade dos resultados. O Quadro 4 relaciona os principais módulos de teste aos riscos que cada um cobre.

Quadro 4 – Módulos de teste e riscos cobertos

Módulo de teste	Risco coberto
test_etl_filters.py	Filtros do universo: estado, rede estadual, escolas em atividade com Ensino Médio
test_panel.py	Integridade da base histórica por escola e ano
test_taxas.py	Leitura das planilhas de rendimento do INEP: cabeçalhos não padronizados e marca de série não ofertada
test_build_target.py	Casamento no tempo: características do ano corrente com o abandono do ano seguinte — um deslocamento de um ano não geraria erro visível
test_models.py	Medidas de desempenho; ausência de vazamento de municípios entre treino e teste; separação temporal sem sobreposição
test_explain.py	Consistência da explicação: a soma das contribuições reproduz a previsão
test_indicadores_gestao.py	Leitura dos indicadores de esforço docente e de complexidade de gestão
test_recommend.py	Camada de serviço do painel: ordenação da lista, marcação de prioridade e diagnóstico
test_predicao.py	Geração da lista para um ano ainda não observado: características idênticas às do treino, ausência de lacunas e falha explícita quando o ano não tem dados

Fonte: elaborado pelo autor.

6.2 Caracterização dos Dados e Análise das Características Usadas

6.2.1 Base Construída

A base histórica reúne 2.392 registros de 806 escolas, 97,4% delas presentes nos três anos, o que garante comparabilidade ao longo do tempo. A rede cobre 185 municípios; 86% das escolas são urbanas e a mediana é de cerca de 350 matrículas de Ensino Médio. Aplicada a regra de casamento no tempo, o conjunto usado na previsão tem 1.586 observações de escola e ano, com 39 características e nenhuma lacuna. O Quadro 5 detalha a passagem de um total ao outro.

Quadro 5 – Do painel histórico ao conjunto usado na previsão

Etapa	Critério	Linhas	Escolas
Painel histórico escola × ano	Escolas estaduais de EM em atividade, 2022 a 2024	2.392	806
Anos que podem servir de origem (t = 2022, 2023)	O ano de 2024 não tem 2025 para observar: entra como alvo, não como origem	-791 → 1.601	804
Pares completos (t → t+1)	Escola sem abandono observado no ano seguinte — saiu da rede ou deixou de ofertar Ensino Médio	-15 → 1.586	801

Fonte: elaborado pelo autor.

A diferença entre os dois totais não decorre de descarte por qualidade. O sistema aprende com pares: os atributos da escola em um ano e o abandono observado no ano seguinte. Com três anos de painel formam-se apenas dois pares por escola, 2022 para 2023 e 2023 para 2024, de modo que as 791 linhas de 2024 não servem de origem, por não haver 2025 a observar. Essas linhas não se perdem: são o alvo das linhas de 2023. Descontadas, restam 1.601 pares potenciais, dos quais 15 não se completam porque a escola não aparece no ano seguinte, tendo saído da rede ou deixado de ofertar Ensino Médio. Chega-se assim às 1.586 observações de escola e ano usadas na previsão.

6.2.2 O Que o Sistema Prevê


O sistema prevê um único indicador: a taxa de abandono no Ensino Médio de cada escola no ano seguinte. Ela é publicada pelo INEP e indica o percentual de alunos matriculados que deixaram a escola durante o ano. Uma escola com 400 alunos e taxa de 5% perdeu 20 estudantes no período.

Duas características desse indicador condicionam todo o projeto. Em 68% das observações a taxa é exatamente zero, ou seja, a maioria das escolas não registra abandono no ano. E o risco é muito desigual entre grupos: em 2024 a taxa média foi de 0,6% nas 679 escolas urbanas (desvio-padrão de 1,8 ponto), 0,9% nas 70 rurais

(desvio-padrão de 1,8) e 6,3% nas 42 escolas indígenas e quilombolas (desvio-padrão de 8,9). O desvio elevado neste último grupo mostra que a média alta não é uniforme: convivem escolas sem abandono algum e escolas com taxas acima de 30%.

A Figura 7 resume esses dois traços. No painel da esquerda, as observações de escola e ano estão distribuídas por faixa de abandono: a barra “nenhum abandono” concentra 68% dos casos, e as faixas seguintes, de baixo a crítico, encolhem rapidamente, de modo que apenas 2% das observações superam 10% de abandono. No painel da direita está a taxa média de 2024 por grupo de localização, que torna visível a desigualdade descrita acima: as barras urbana e rural ficam próximas de zero, enquanto a das escolas indígenas e quilombolas se destaca, mais de dez vezes acima. Juntos, os dois painéis explicam por que o valor médio da taxa diz pouco e por que o esforço do sistema se volta para ordenar as escolas por risco.

Figura 7 – Distribuição da taxa de abandono prevista e diferença de risco entre grupos de escolas



Fonte: elaborado pelo autor.

6.2.3 Análise Estatística das Características Contínuas

Cada uma das 39 características foi analisada antes de entrar no sistema, com o tratamento adequado ao seu tipo: 23 são contínuas, 15 são de sim ou não e uma é categórica. As 23 contínuas estão no Quadro 6, com o valor típico da rede, a dispersão em torno dele e a relação de cada uma com o abandono do ano seguinte. As taxas de rendimento e os quatro indicadores educacionais que aparecem no quadro merecem definição. As taxas de abandono e de reprovação do ano anterior são percentuais de matrículas publicados pelo INEP, apresentados para o Ensino Médio como um todo e para cada série.

A distorção idade-série, referida no restante do texto e nos quadros do Apêndice A também como defasagem idade-série, é o percentual de alunos com dois anos ou mais acima da idade esperada para a série que cursam.

O nível socioeconômico (INSE) é uma escala contínua calculada pelo INEP a partir do perfil das famílias dos alunos (BRASIL, 2024b): escolaridade dos pais, renda e bens do domicílio. Valores maiores indicam comunidades mais favorecidas. Entre as 69.820 escolas brasileiras avaliadas em 2021 a escala vai de 2,45 a 6,85; nesta rede, varia de 2,97 a 6,10, com média de 4,46.

A adequação da formação docente reparte os professores da escola em cinco grupos que somam 100%. O Grupo 1 reúne os professores com licenciatura na própria disciplina que lecionam, a formação considerada ideal; o Grupo 3, os de licenciatura em área diferente; e o Grupo 5, os sem ensino superior. Apenas esses três entram no sistema, por resumirem os dois extremos e o caso intermediário mais comum.

Por fim, a regularidade do corpo docente (IRD) mede, numa escala de 0 a 5, a permanência dos mesmos professores na escola ao longo dos anos: valores altos indicam um quadro estável.

As colunas do quadro respondem a perguntas diferentes. A média é o valor típico da rede, e o desvio-padrão diz o quanto as escolas se afastam dele: quanto maior, mais desigual é a rede naquela característica. Mínimo, mediana e máximo descrevem a distribuição. A mediana divide a rede ao meio; quando fica muito abaixo da média, indica que poucas escolas com valores altos puxam o resultado para cima. A última coluna resume a relação de cada característica com o abandono do ano seguinte, num indicador que varia de -1 a +1. Positivo significa que a característica acompanha o aumento do abandono; negativo, que acompanha a redução. Quanto mais distante de zero, mais forte a associação. Os asteriscos indicam a confiança do resultado (* 95%, ** 99%, *** 99,9%); sem asterisco, a relação não se distingue do acaso. As unidades variam conforme a linha: taxas e proporções estão em pontos percentuais, e as demais seguem as escalas descritas acima. O porte é a única característica transformada — entra como logaritmo do número de matrículas, para que escolas muito grandes não dominem a comparação. Por isso a mediana de 5,87 corresponde a cerca de 350 matrículas.

Quadro 6 – Estatísticas descritivas das 23 características contínuas e relação de cada uma com o abandono do ano seguinte

Característica	Média	Desvi o-padrão	Mínimo	Mediana	Máximo	Rela ção com o abandono
Abandono no ano anterior (Ensino Médio)	1,72	4,80	0,00	0,00	43,60	0,48 ***
Abandono no ano anterior — 1ª série	2,19	5,97	0,00	0,00	52,60	0,46 ***
Abandono no ano anterior — 2ª série	1,51	4,48	0,00	0,00	47,90	0,45 ***
Abandono no ano anterior — 3ª série	0,94	3,98	0,00	0,00	50,00	0,37 ***
Distorção idade- série — 1ª série	26,89	14,33	0,00	25,20	97,80	0,27 ***
Distorção idade- série (Ensino Médio)	23,29	12,96	1,30	21,35	97,40	0,27 ***
Distorção idade- série — 2ª série	22,22	12,97	0,00	20,25	100,00	0,25 ***
Adequação da formação docente — Grupo 5	3,06	14,38	0,00	0,00	100,00	0,21 ***
% de matrículas em tempo integral	59,63	44,87	0,00	88,24	100,00	- 0,21***
Distorção idade- série — 3ª série	18,29	12,80	0,00	15,50	100,00	0,19 ***
Reprovação no ano anterior (Ensino Médio)	4,55	4,68	0,00	3,50	55,30	0,18 ***
Adequação da formação docente — Grupo 1	54,31	14,64	0,00	55,25	92,10	- 0,17***
Nível socioeconômico (INSE)	4,46	0,30	2,97	4,45	6,10	- 0,17***
Reprovação no ano anterior — 1ª série	6,05	5,65	0,00	4,80	50,00	0,16 ***
Alunos por turma	33,10	6,96	5,00	34,22	50,00	- 0,16***
Reprovação no ano anterior — 2ª série	4,51	4,66	0,00	3,40	32,10	0,13 ***
Índice de infraestrutura	0,64	0,18	0,09	0,67	1,00	- 0,12***
Reprovação no ano anterior — 3ª série	1,70	3,15	0,00	0,55	38,50	0,12 ***
Alunos por docente	18,29	5,95	1,00	18,82	34,25	- 0,09***
Regularidade do corpo docente (IRD)	3,36	0,49	1,84	3,36	4,86	0,08 **
Computadores por aluno	0,07	0,11	0,00	0,04	2,00	- 0,08**

Porte (logaritmo do nº de matrículas)	5,73	0,71	2,08	5,87	7,23	-
Adequação da formação docente — Grupo 3	39,44	13,06	0,00	40,20	100,00	0,01


Fonte: elaborado pelo autor.

Nota: as taxas de Ensino Médio publicadas pelo INEP agregam a 1ª, 2ª e 3ª séries, a 4ª série e a matrícula não seriada (educação de jovens e adultos e organização modular). Por isso o valor da rede pode superar o máximo observado em qualquer série isolada: o máximo de 55,3% na reprovação corresponde a uma escola cuja matrícula de Ensino Médio é integralmente não seriada. As 283 observações nessa situação, 17,8% do conjunto, estão identificadas pelo atributo “Oferta de EM fora das séries regulares”, no Quadro 7. Nessas escolas, os valores por série são estimados pela média da mesorregião no mesmo ano, e não devem ser lidos como observação direta.

O quadro revela três padrões que condicionam o restante do trabalho. As características de fluxo concentram-se em zero: metade das escolas não registrou abandono no ano anterior, e a média de 1,72% é puxada por poucas escolas com valores muito altos, até 43,6%. O tempo integral comporta-se de forma quase binária, com a rede dividida entre escolas totalmente integrais e escolas sem nenhuma matrícula nessa modalidade, e pouca coisa no meio. Já a defasagem idade-série distribui-se de maneira equilibrada, em torno de 23%, o que a torna especialmente útil para diferenciar escolas. A Figura 8 reúne a distribuição das 23 características em um único painel.

Figura 8 – Distribuição das 23 características contínuas na rede estadual

Como cada característica contínua se distribui na rede estadual
(linha tracejada: mediana)



Fonte: elaborado pelo autor.

6.2.4 Análise Estatística das Características de Sim ou Não

As 15 características de sim ou não são comparadas de outra forma: qual o abandono médio das escolas que têm o atributo e das que não têm. A maior diferença está na localização, não na infraestrutura. Escolas indígenas e quilombolas têm abandono médio de 8,95%, contra 0,70% das demais; as rurais, 3,74% contra 0,70%. Os itens de infraestrutura produzem diferenças bem menores, de 0,5 a 2 pontos percentuais, mas todas na mesma direção: escolas com biblioteca, laboratórios, quadra e internet para alunos abandonam menos.

O Quadro 7 reúne duas leituras distintas de cada atributo, e vale distingui-las. As duas primeiras colunas repartem as 1.586 observações entre as escolas que têm o atributo e as que não têm, e por isso se completam: somadas, dão o total da rede. As duas colunas seguintes são de outra natureza, pois cada uma traz a taxa média de abandono no ano seguinte dentro de um desses grupos. São duas médias do mesmo indicador, medidas em conjuntos diferentes de escolas, e não há razão para que se somem a 100%; o que interessa nelas é a distância entre uma e outra, registrada na última coluna. As contagens aparecem ao lado dos percentuais porque a comparação só se sustenta quando os dois grupos têm tamanho suficiente.


Quadro 7 – Repartição das escolas por atributo de sim ou não e abandono médio de cada grupo

Atributo	Escolas que têm	Escolas que não têm	Abando no médio se tem	Abando no médio se não tem	Diferen ça (p.p.)
Localização diferenciada (indígena/quilombola)	81 (5,1%)	1.505 (94,9%)	8,95%	0,70%	8,25***
Localização rural	218 (13,7%)	1.368 (86,3%)	3,74%	0,70%	3,04***
Biblioteca	1.438 (90,7%)	148 (9,3%)	0,93%	3,01%	-2,08**
Laboratório de informática	1.228 (77,4%)	358 (22,6%)	0,74%	2,44%	-1,71**
Banda larga	1.393 (87,8%)	193 (12,2%)	0,95%	2,34%	-1,39
Quadra de esportes	1.120 (70,6%)	466 (29,4%)	0,79%	1,93%	-1,14*
Laboratório de ciências	705 (44,5%)	881 (55,5%)	0,53%	1,59%	-1,06**
Esgoto em rede pública	952 (60,0%)	634 (40,0%)	0,74%	1,70%	-0,96
Água potável	1.509 (95,1%)	77 (4,9%)	1,08%	1,91%	-0,83
Internet para alunos	1.170 (73,8%)	416 (26,2%)	0,92%	1,69%	-0,77**
Internet	1.574 (99,2%)	12 (0,8%)	1,12%	1,84%	-0,73
Refeitório	511 (32,2%)	1.075 (67,8%)	0,73%	1,31%	-0,58*
Auditório	438 (27,6%)	1.148 (72,4%)	0,75%	1,26%	-0,52
Oferta de EM fora das séries regulares (EJA/modular)	283 (17,8%)	1.303 (82,2%)	1,49%	1,04%	0,45***
Sala de leitura	244 (15,4%)	1.342 (84,6%)	1,38%	1,07%	0,30

Fonte: elaborado pelo autor.

Atributos presentes em quase toda a rede não separam grupos porque não sobra comparação: internet está em 99,2% das escolas e água potável em 95,1%, restando 12 e 77 escolas do outro lado. As diferenças que essas linhas exibem não são estatisticamente distinguíveis do acaso e não devem ser lidas como efeito do atributo. A Figura 9 apresenta a mesma comparação em forma gráfica.

Figura 9 – Repartição das escolas por atributo de sim ou não e taxa média de abandono de cada grupo



Fonte: elaborado pelo autor.

6.2.5 A Região do Estado

A única característica categórica é a região do estado. As cinco regiões diferem de forma marcante, e a diferença entre elas é estatisticamente comprovada: o São Francisco Pernambucano tem abandono médio de 2,76%, mais de cinco vezes o da Região Metropolitana de Recife, de 0,50%, que concentra um terço das observações. Essa diferença justifica manter a região entre as características do sistema. O Quadro 8 e a Figura 10 detalham o peso de cada região no conjunto de dados e o abandono médio observado em cada uma.


Quadro 8 – Distribuição das observações e abandono médio por região do estado

Região do estado	Observações	% do conjunto	Abandono médio
São Francisco Pernambucano	227	14,3%	2,76%
Sertão Pernambucano	237	14,9%	1,53%
Agreste Pernambucano	366	23,1%	1,08%

Mata Pernambucana	233	14,7%	0,57%
Metropolitana de Recife	523	33,0%	0,50%

Fonte: elaborado pelo autor.

Figura 10 – Abandono médio e peso de cada região do estado no conjunto de dados




Fonte: elaborado pelo autor.

6.2.6 Quais Características Têm Valor para a Previsão

Reunindo as duas famílias numéricas, 30 das 38 características têm relação estatisticamente comprovada com o abandono do ano seguinte. As oito restantes não se separaram do acaso: Porte (nº de matrículas), Adequação da formação docente — Grupo 3, Banda larga, Esgoto em rede pública, Água potável, Internet, Auditório e Sala de leitura. Elas foram mantidas por dois motivos: a ausência de relação isolada não impede que a característica seja útil em combinação com as demais, e o conjunto já é enxuto o bastante para que o custo de mantê-las seja pequeno. Na prática, o próprio sistema lhes atribui pouco peso. A Figura 11 ordena todas as características numéricas por essa relação.

Figura 11 – As 38 características numéricas ordenadas pela relação com o abandono do ano seguinte



Fonte: elaborado pelo autor.

As características de maior valor formam três blocos. O mais forte, de longe, é o histórico recente da própria escola: abandono e reprovação do ano anterior. Vem depois o perfil dos alunos, com a defasagem idade-série e o nível socioeconômico. Por último, o contexto: localização diferenciada, zona rural e região do estado. A infraestrutura tem efeito real, porém modesto, e o porte da escola, isoladamente, não guarda relação detectável com o abandono.

Dois indicadores adicionais do INEP, o esforço docente e a complexidade de gestão, foram submetidos ao mesmo critério e não entraram no sistema. O esforço docente tem relação fraca com o abandono; a complexidade de gestão repete a informação já trazida pela defasagem idade-série. Uma comparação controlada, com e sem os dois, confirmou a ausência de ganho: a qualidade da ordenação ficou praticamente idêntica e o erro médio piorou ligeiramente. Contratar um segundo funcionário para o

serviço que o primeiro já faz não aumenta a produção. Ambos permanecem no projeto apenas como caracterização descritiva da rede.

A caracterização das escolas fixa o critério que orienta o restante do capítulo. Como o que se exige do sistema é colocar no topo da lista as escolas que de fato terão abandono alto, a avaliação a seguir julga sobretudo a ordem prevista, e não o valor exato da taxa.

6.3 Desempenho do Sistema

6.3.1 Como o Desempenho Foi Medido

O desempenho foi medido sob dois protocolos complementares. O primeiro repete 20 vezes uma divisão em que 20% dos municípios ficam de fora do treino, o que produz uma faixa de confiança em vez de um número solitário e impede que escolas do mesmo município apareçam dos dois lados. O segundo é mais exigente: treinar com o par 2022–2023 e prever o par 2023–2024, isto é, um ano que o sistema nunca viu. É esse que simula o uso real. Ambos seguem a recomendação de que dados com estrutura espacial ou temporal exijam esquemas de validação capazes de separar os blocos dependentes, sob pena de superestimar o desempenho (ROBERTS et al., 2017).

Três medidas são reportadas. O erro médio da taxa prevista, em pontos percentuais (RMSE), diz o quanto o sistema erra o valor. O acerto da ordenação, numa escala de 0 a 1 (correlação de Spearman), diz o quanto a ordem prevista se aproxima da observada. E o acerto na lista prioritária (Precision@K) diz, entre as 10% de escolas apontadas como mais críticas, quantas realmente estavam entre as mais críticas. As duas últimas são as que importam para o propósito do sistema.

Antes da comparação entre modelos, convém responder em termos diretos quanto o sistema erra e quanto acerta. No cenário que simula o uso real, ele erra o valor da taxa de abandono de cada escola em cerca de 2,9 pontos percentuais — o equivalente a cerca de 3 alunos por escola —, de modo que a taxa prevista não deve ser lida como um número exato. O acerto está em indicar quem precisa de atenção primeiro: de cada dez escolas que o sistema coloca no topo da lista de prioridade, cerca de quatro estavam de fato entre as de maior abandono, contra menos de uma se a lista fosse montada ao acaso. É essa capacidade de ordenar, e não o valor exato da taxa, que constitui a contribuição do sistema; os quadros seguintes detalham esses números.

6.3.2 Resultados em Validação Repetida

O Quadro 9 reúne o desempenho dos quatro modelos — o piso trivial da média da rede, os dois modelos de referência e o modelo adotado (XGBoost) — sob o primeiro protocolo, com a faixa de confiança obtida nas 20 repetições.


Quadro 9 – Desempenho em validação repetida (20 repetições, com faixa de confiança de 95%)

Modelo	Erro médio da taxa (p.p.)	Acerto da ordenação (0 a 1)	Acerto na lista prioritária
Sem sistema (média da rede)	3,154 [2,730; 3,577]	—	0,068 [0,040; 0,096]
Modelo de referência linear	2,628 [2,349; 2,907]	0,428 [0,392; 0,463]	0,513 [0,472; 0,553]
Modelo de referência em árvores	2,546 [2,281; 2,812]	0,431 [0,400; 0,463]	0,501 [0,457; 0,545]
Modelo adotado	2,597 [2,329; 2,865]	0,416 [0,387; 0,445]	0,504 [0,457; 0,550]

Fonte: elaborado pelo autor.

O Quadro 9 responde, na validação repetida, às duas perguntas que importam: quanto cada modelo erra e quanto acerta. O erro médio melhora pouco (2,6 pontos percentuais no modelo adotado, contra 3,2 do palpite pela média da rede): o sistema continua errando o valor exato da taxa. Já a ordenação e o acerto da lista prioritária melhoram muito em relação à média da rede. Na ordenação os três modelos ficam praticamente empatados, com intervalos de confiança que se sobrepõem e sem vencedor claro. O modelo adotado acompanha os demais: das escolas que ele aponta como prioritárias, cerca de metade estava de fato entre as mais críticas, contra 7 em cada 100 na escolha ao acaso, sete vezes mais. A Figura 12 mostra como essas três medidas se distribuem ao longo das 20 repetições.

Figura 12 – Distribuição das medidas de desempenho nas 20 repetições



Fonte: elaborado pelo autor.

6.3.3 Resultados no Teste do Ano Nunca Visto

O Quadro 10 repete a comparação sob o segundo protocolo, em que o modelo aprende com os pares de 2022 e 2023 e é avaliado num ano que nunca viu.

Quadro 10 – Desempenho no teste do ano nunca visto (treino em 2022–2023, teste em 2023–2024)

Modelo	Erro médio da taxa (p.p.)	Acerto da ordenação (0 a 1)	Acerto na lista prioritária	Separação entre críticas e não críticas
Sem sistema (média da rede)	2,540	—	0,089	—
Modelo de referência linear	2,891	0,330	0,380	0,812
Modelo de referência em árvores	2,751	0,343	0,405	0,829
Modelo adotado	2,874	0,348	0,418	0,798

Fonte: elaborado pelo autor.

O Quadro 10 traz o achado mais relevante da avaliação. Entre um ciclo e outro o abandono médio da rede caiu, e nenhum modelo superou o piso trivial no erro de magnitude: todos erram sistematicamente o nível da taxa. Em números, o modelo adotado erra a taxa de cada escola em 2,9 pontos percentuais, em média, ante 2,5 de quem simplesmente repete a média da rede para todas as escolas. As medidas de ordenação, porém, permanecem muito acima do piso. O sistema continua identificando quais escolas terão abandono alto, mesmo errando o valor. Das 79 escolas que ele coloca no topo da lista (10% da rede do ano de teste), 33 estavam de fato entre as de maior abandono; a escolha ao acaso acertaria 7 — um ganho de quase cinco vezes.

O sistema se comporta como um termômetro descalibrado: erra alguns graus, mas aponta corretamente quem está com mais febre. Para priorizar intervenções, é a ordem que importa. A limitação de magnitude vem da janela curta de dados, apenas dois pares de anos, e está registrada entre as limitações do estudo.

A última coluna traduz o mesmo resultado em uma medida comparável à da literatura, que costuma tratar evasão como uma classificação: a capacidade de separar as escolas críticas das demais chega a 0,798 para o modelo adotado, na faixa típica dos estudos da área.

Entre modelos tão próximos, o XGBoost foi mantido como modelo adotado por duas razões, reconhecendo-se que a escolha não é imposta pelos números. A primeira tem a ver com o propósito do sistema. Como o objetivo é priorizar, isto é, ordenar as

escolas por risco, as medidas que mais importam são a ordenação e o acerto da lista prioritária. É nelas que o modelo adotado se sai melhor no teste do ano nunca visto, o cenário que reproduz o uso real. O modelo de referência em árvores leva vantagem no erro de magnitude e na separação entre escolas críticas e não críticas, dimensões menos centrais para a decisão de onde intervir primeiro. A segunda razão é prática: é sobre o modelo adotado que se constroem as explicações apresentadas na seção seguinte. Como as diferenças entre os três modelos permanecem dentro da margem de incerteza, a escolha não representa perda de desempenho relevante.

6.3.4 Resultados em Cada Transição Anual

Para examinar se o desempenho se sustenta de um ano para o outro, o modelo adotado foi avaliado nos dois cenários anuais em separado: no primeiro, usa as características de 2022 para prever o abandono de 2023; no segundo, usa as de 2023 para prever o de 2024. Em cada cenário o desempenho é medido fora da amostra, repetindo vinte vezes uma divisão em que 20% dos municípios daquele ano ficam de fora do treino, a mesma régua do Quadro 9, aqui separada por ano em vez de agregada. É sempre o mesmo modelo; muda apenas o ano de referência. O Quadro 11 reúne os resultados dos dois cenários.

Quadro 11 – Desempenho do modelo adotado em cada transição anual (média e faixa de confiança de 95% sobre 20 repetições)


Indicador de desempenho	Cenário 2022 → 2023	Cenário 2023 → 2024
Erro médio da taxa, p.p. (RMSE) — menor é melhor	2,82 ± 0,34	2,16 ± 0,26
Acerto da ordenação, de 0 a 1 (Spearman)	0,469 ± 0,039	0,367 ± 0,032
Acerto na lista prioritária, top 10% (Precision@K)	0,627 ± 0,060	0,381 ± 0,041
Separação alto/baixo risco (ROC-AUC)	0,901 ± 0,035	0,813 ± 0,019

Fonte: elaborado pelo autor.

O modelo mantém utilidade nas duas transições, mas rende mais na primeira. Na transição de 2022 para 2023, 63% das escolas que ele coloca no topo da lista estão de fato entre as de maior abandono. Na de 2023 para 2024, esse acerto cai para 38% — ainda muito acima dos cerca de 10% de uma escolha ao acaso. A queda acompanha a própria mudança da rede: o abandono médio caiu de 1,36% para 0,88% e as escolas se aproximaram de zero, o que reduz o erro absoluto e

comprime o sinal que permite ordená-las. Mesmo no cenário mais difícil, a capacidade de separar as escolas de alto risco das demais permanece alta (0,81 numa escala em que 0,5 é o acaso). Os dois cenários cercam os valores do Quadro 9, que avalia as duas transições agregadas — sinal de que a decomposição é coerente com o desempenho global. A Figura 13 apresenta os dois cenários lado a lado.


Figura 13 – Desempenho do modelo adotado em cada transição anual (2022→2023 e 2023→2024)



Fonte: elaborado pelo autor.

A mesma comparação entre os dois anos pode ser lida em número de alunos, e não em taxa. Convertendo a taxa de abandono de cada escola em quantidade de estudantes, ou seja, multiplicando-a pela matrícula do ensino médio no ano em que o abandono é medido, o resíduo passa a exprimir quantos alunos o sistema errou, para mais ou para menos, em cada escola. A Figura 14 apresenta esse resíduo, escola a escola, nas duas transições. Em ambas, a maioria das escolas concentra-se em torno de zero e o erro médio é de cerca de três alunos por escola (3,3 na transição de 2022 para 2023 e 3,0 na de 2023 para 2024), sem tendência sistemática de superestimar ou subestimar; as poucas escolas de maior porte, com dezenas de evasões, concentram os maiores desvios.

Figura 14 – Resíduo do modelo por escola, em número de alunos que abandonaram o ensino médio, nas transições 2022–2023 e 2023–2024




Fonte: elaborado pelo autor.

6.4 Capacidade de Priorização

Do ponto de vista do gestor, a pergunta operacional é direta: com recursos para atender um número limitado de escolas indicadas pelo sistema, quantas das escolas realmente críticas são alcançadas? A resposta é obtida variando o tamanho da lista, sem reconstruir o sistema: como ele prevê uma taxa, e não um rótulo de “em risco” ou “fora de risco”, o ponto de corte da lista pode ser escolhido depois, conforme o orçamento disponível.

Considerando críticas as escolas do décimo mais alto de abandono em 2024, e usando o modelo treinado apenas com os anos anteriores, a lista das 50 primeiras alcança 28% das críticas, contra 6% da escolha ao acaso. A das 100 primeiras alcança 46% e a das 150 primeiras, 57%. Vale aqui o princípio da triagem de um pronto-socorro: com vagas limitadas, a fila ordenada por gravidade encontra muito mais casos graves do que o atendimento por ordem de chegada. A Figura 15 compara o alcance da lista do sistema com o da escolha ao acaso, e a Figura 16 mostra como o acerto e o alcance variam conforme o tamanho da lista.


Figura 15 – Ganho prático da lista de prioridade em relação à escolha ao acaso



Fonte: elaborado pelo autor.

Figura 16 – Acerto e alcance da lista para diferentes tamanhos de lista

M5 — Ranking flexível: desempenho por tamanho da lista de priorização (teste temporal 2023→2024)




Fonte: elaborado pelo autor.

6.5 Explicação das Indicações

6.5.1 Visão Geral

Saber que uma escola está no topo da lista não basta; é preciso saber por quê. A técnica de explicação adotada é o SHAP (LUNDBERG; LEE, 2017), apresentado no Capítulo 2, que decompõe cada previsão na contribuição de cada característica. Aplicada a todo o conjunto, ela ordena as características por peso nas previsões do sistema. No topo está o abandono do ano anterior na 2ª série, seguido da defasagem idade-série. Vêm depois o abandono do Ensino Médio como um todo e o da 1ª série. Aparecem então a localização diferenciada — peso retomado adiante, em Erros do Modelo e Equidade — e a reprovação do ano anterior. Somadas, as medidas do ano anterior respondem pela maior parte do peso total. Esse peso confirma um princípio conhecido: o melhor predictor do tempo de amanhã costuma ser o tempo de hoje. A Figura 17 ordena as características por esse peso.

Figura 17 – Contribuição de cada característica para as previsões do sistema




Fonte: elaborado pelo autor.

6.5.2 Direção dos Efeitos

As contribuições também têm direção, e ela é coerente com o que se espera. Valores altos de abandono e de reprovação no ano anterior e de defasagem idade-série empurram a previsão para cima, aumentando o risco. Valores altos de nível socioeconômico e de formação docente adequada empurram para baixo. Essa coerência é um argumento de confiança: o sistema não está apenas acertando, está acertando pelas razões certas. A Figura 18 reúne, para cada característica, o peso e a direção de sua contribuição.

Figura 18 – Peso e direção de cada característica nas previsões do sistema




Fonte: elaborado pelo autor.

6.5.3 Explicação de Uma Escola

A decomposição também vale caso a caso. Para qualquer escola é possível mostrar como cada característica afastou sua previsão da média da rede, o que separa o mapa do clima de um país da previsão do tempo de uma cidade. Na escola de maior risco previsto, uma estadual indígena no município de Jatobá, as maiores contribuições positivas vêm da defasagem idade-série, do histórico de abandono e do abandono na 2ª série, como mostra a Figura 19. É essa explicação que o painel apresenta ao gestor para justificar cada indicação.

Figura 19 – Explicação individual da escola de maior risco previsto



Fonte: elaborado pelo autor.

6.5.4 Erros do Modelo e Equidade


A análise dos erros por grupo revelou um achado de equidade que precisa ser declarado, na linha do que a literatura recomenda para sistemas preditivos aplicados a políticas públicas (BAROCAS; HARDT; NARAYANAN, 2023). No teste do ano nunca visto, o sistema erra para mais nas escolas de localização diferenciada: prevê risco alto para escolas indígenas e quilombolas cujo abandono observado é próximo de zero. O erro médio nesse grupo é de -6,12 pontos percentuais, contra +0,07 nas urbanas e +0,38 nas rurais.

A explicação provável é a existência de fatores de proteção ligados ao vínculo comunitário, que os dados disponíveis não capturam. O perfil dessas escolas, rural, de baixo nível socioeconômico e com alta defasagem idade-série, está associado a

abandono alto, mas o abandono observado não acontece. É o que faz um seguro de automóvel cobrar caro de um motorista pelo perfil de risco, sem saber que ele dirige pouco e com cuidado.

A consequência prática é direta: sem correção, o sistema daria atenção excessiva a escolas que não estão de fato em risco, deslocando recursos de onde eles são necessários. A limitação está registrada no painel e é o primeiro item dos trabalhos futuros. A Figura 20 compara o erro médio do sistema entre os grupos de localização.

Figura 20 – Erro do sistema por grupo de localização no teste do ano nunca visto



Fonte: elaborado pelo autor.

6.6 O Painel de Priorização ao Gestor

O sistema culmina em um painel interativo que coloca o modelo nas mãos do gestor, atendendo às três funções previstas na arquitetura. A primeira é a lista de risco das escolas para o ano seguinte, com filtros por região e município e marcação das escolas mais críticas. A segunda é o detalhe de cada escola: o risco previsto, sua posição na lista e a explicação de quais características puxaram aquela previsão para cima ou para baixo, o equivalente a um laudo individual. A terceira é o diagnóstico, que separa as escolas que abandonam mais do que o previsto, e merecem alerta, das que abandonam menos, e merecem estudo.

Uma ressalva fica explícita na própria tela: as previsões exibidas foram calculadas sobre dados que o modelo conhece, e a estimativa honesta de desempenho é a do teste do ano nunca visto. O painel é uma ferramenta de apoio à decisão, não um substituto do julgamento do gestor. Ele responde a duas perguntas no mesmo lugar: onde intervir primeiro e por quê.

6.7 Síntese dos Resultados

Cinco resultados resumem o trabalho. O sistema é confiável no que se propõe: uma suíte de 138 testes cobre os erros que passariam despercebidos, e os resultados são reproduzíveis a partir dos dados originais.

O conjunto de características é enxuto e justificado, com 39 colunas escolhidas entre mais de 400, cada uma submetida a análise estatística individual e a critérios explícitos de corte.

O sistema acerta a ordem, não a magnitude. Ele erra o valor exato da taxa, mas ordena as escolas com qualidade útil, e é a ordem que a decisão do gestor requer.

O ganho prático é mensurável: das escolas apontadas como prioritárias, cerca de metade estava de fato entre as mais críticas, contra 7 em cada 100 na escolha ao acaso, e uma lista de 150 escolas alcança mais da metade das escolas críticas da rede.

Por fim, cada indicação é explicável. Isso permite ao gestor concordar ou discordar com argumento e é também o que expõe, de forma transparente, a limitação de equidade nas escolas de localização diferenciada.

7 CONCLUSÕES E TRABALHOS FUTUROS

7.1 Conclusões

Este trabalho desenvolveu um sistema de identificação precoce do risco de evasão em escolas estaduais de Ensino Médio de Pernambuco, do tratamento dos dados públicos à entrega de um painel operacional ao gestor.

Resposta à pergunta de previsão (P1). Sim, com uma qualificação que é ela própria um resultado: o sistema identifica quais escolas terão abandono elevado, mas não estima quanto. O acerto da ordenação foi de 0,416 na validação repetida e de 0,348 no teste do ano nunca visto, e a capacidade de separar as escolas críticas das demais chegou a 0,798. Das escolas apontadas como prioritárias, cerca de metade estava de fato entre as mais críticas, contra 7 em cada 100 na escolha ao acaso. O erro de magnitude, por outro lado, não superou o piso trivial no teste temporal: entre um ciclo e outro o abandono médio da rede caiu, e o sistema errou sistematicamente o nível da taxa. Como a decisão do gestor exige a ordem das escolas e não o valor previsto, a pergunta está respondida no que importa, e a limitação de magnitude é atribuída à janela curta de apenas dois pares de anos.

Resposta à pergunta de diagnóstico (P2). Sim. A comparação entre o abandono observado e o que o perfil de cada escola faria esperar identificou os dois extremos, registrados para inspeção: as vinte escolas que mais abandonam acima do esperado e as vinte que mais ficam abaixo, com desvios que vão de -27,87 a +23,69 pontos percentuais. Esse diagnóstico chega ao gestor no painel, que classifica cada escola em alerta ou resiliente. Uma ressalva é necessária: parte do que a análise encontra descreve o limite do sistema, e não a escola. As escolas indígenas e quilombolas aparecem sistematicamente entre as que abandonam menos do que o previsto porque faltam ao modelo os fatores de proteção comunitários discutidos no Capítulo 6. Distinguir as duas leituras, a escola que foge ao padrão e o modelo que não enxerga um fator, faz parte da resposta.

Sobre o problema: a evasão na rede estadual é concentrada, não difusa. Em 2024, 10% das escolas responderam por 76% dos alunos que abandonaram, enquanto dois terços das escolas não registraram nenhum caso. Esse recorte é o que justifica um sistema de priorização em vez de um acompanhamento pela média da rede: um sistema que respondesse “zero” para todas as escolas erraria pouco na média e ainda assim seria inútil ao gestor, porque o que a decisão exige é a ordem das escolas, não o valor da taxa.

Sobre as características: partiu-se de mais de 400 colunas disponíveis para 39, escolhidas com critérios explícitos e submetidas a análise estatística individual. Trinta das 38 características numéricas mostraram relação comprovada com o abandono do ano seguinte, e as de maior valor são o histórico recente da própria escola, o perfil dos alunos e o contexto de localização.

Sobre o desempenho: o sistema ordena as escolas com qualidade útil para a gestão, ainda que não acerte o valor exato da taxa. No teste mais exigente, uma lista de 150 escolas alcança 57% das escolas críticas da rede, contra 19% da escolha ao acaso.

Sobre a engenharia: o sistema foi construído com arquitetura em camadas, dependências em sentido único, 138 testes automatizados e reprodutibilidade completa a partir dos dados originais. Essas propriedades não são acessórias: em um sistema que aprende com dados, elas são a única defesa contra erros que não se manifestam em tempo de execução.

Sobre os limites: o sistema erra para mais nas escolas indígenas e quilombolas, prevendo risco onde o abandono observado é baixo. A limitação está documentada, exposta no painel e é o primeiro item dos trabalhos futuros. Reconhecê-la faz parte da entrega.

Sobre o que o sistema não garante: prever evasão não é o mesmo que conhecê-la. A decisão de deixar a escola é de um estudante, e o que pesa nela — trabalho, gravidez, mudança de cidade, doença, violência, perda de vínculo com o estudo — não está em nenhuma das 39 características, que descrevem a escola, não o aluno. O sistema encontra associações, não causas. Ele não garante que uma escola apontada terá abandono alto, nem que uma escola fora da lista esteja em segurança: cerca de metade das prioritárias não está entre as mais críticas, e o acerto da lista caiu de 0,627 para 0,381 de uma transição anual para a outra. Nas escolas indígenas e quilombolas, erra com confiança sobre um grupo inteiro. A lista diz onde olhar primeiro; quem confirma é a visita à escola.

7.2 Trabalhos Futuros

Correção do viés de equidade: ajustar o tratamento das escolas de localização diferenciada, por calibração específica do grupo ou por modelagem que reconheça a sua particularidade, e investigar quais fatores de proteção explicam o baixo abandono observado nessas escolas.

Ampliação da base: incorporar séries históricas mais longas, que devem reduzir a limitação de magnitude observada, e integrar outras fontes públicas que enriqueçam o perfil das escolas.

Evolução do sistema: empacotar a aplicação em contêiner para implantação, implementar o monitoramento contínuo do modelo com reavaliação periódica e integrar o painel aos sistemas da Secretaria para o envio automático de alertas.

Avaliação em uso: realizar um estudo com gestores da Secretaria para medir a usabilidade do painel e o efeito das intervenções priorizadas pelo sistema, verificação final de que a ferramenta cumpre o propósito para o qual foi construída.

Medida de incerteza: entregar cada escola com um intervalo, não com um número só. Escolas pequenas, em que a saída de poucos alunos muda a taxa, precisam chegar ao gestor com essa ressalva visível.

Dados por aluno: a evasão acontece na trajetória de cada estudante, e o sistema só enxerga a escola. Registros de matrícula, frequência e notas, respeitada a proteção de dados pessoais, permitiriam estimar o risco individual.

Sinais durante o ano: hoje a lista sai uma vez por ano. Frequência e notas por bimestre permitiriam recalcular o risco enquanto ainda há tempo de agir.

Monitoramento de deriva: o abandono da rede caiu de 2,05% para 0,96% entre 2022 e 2024, e foi isso que degradou a previsão de magnitude. O sistema precisa avisar sozinho quando os dados novos se afastam daqueles em que aprendeu.

Validação em outra rede: aplicar o mesmo protocolo fora de Pernambuco separaria o que é método do que é particularidade desta rede.

Comparação de modelos com mais dados: os três modelos avaliados empataram dentro da margem de incerteza. Com séries mais longas, a comparação deve ser refeita.

REFERÊNCIAS

- BAKER, R. S. J. D.; YACEF, K. The state of educational data mining in 2009: a review and future visions. *Journal of Educational Data Mining*, v. 1, n. 1, p. 3–16, 2009.
- BAROCAS, S.; HARDT, M.; NARAYANAN, A. Fairness and machine learning: limitations and opportunities. Cambridge: MIT Press, 2023.
- BOWERS, A. J.; SPROTT, R.; TAFF, S. A. Do we know who will drop out? A review of the predictors of dropping out of high school: precision, sensitivity, and specificity. *The High School Journal*, v. 96, n. 2, p. 77–100, 2013.
- BRASIL. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. Censo Escolar da Educação Básica: microdados 2022–2024. Brasília: INEP, 2024a.
- BRASIL. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. Indicadores educacionais: INSE, IRD, TDI e AFD. Brasília: INEP, 2024b.
- BRASIL. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. Taxas de rendimento escolar: 2022–2024. Brasília: INEP, 2024c.
- BREIMAN, L. Random forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.
- CHAPMAN, P. et al. CRISP-DM 1.0: step-by-step data mining guide. Copenhagen: SPSS, 2000.
- CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. In: *PROCEEDINGS OF THE 22ND ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING*, 2016, São Francisco. Anais [...]. New York: ACM, 2016. p. 785–794.
- CORTEZ, P.; SILVA, A. Using data mining to predict secondary school student performance. In: *FUTURE BUSINESS TECHNOLOGY CONFERENCE*, 5., 2008, Porto. Anais [...]. [S. l.]: EUROSIS, 2008. p. 5–12.
- FREIRE, P. *Pedagogia do oprimido*. 17. ed. Rio de Janeiro: Paz e Terra, 1987.
- GUYON, I.; ELISSEEFF, A. An introduction to variable and feature selection. *Journal of Machine Learning Research*, v. 3, p. 1157–1182, 2003.
- HARRIS, C. R. et al. Array programming with NumPy. *Nature*, v. 585, n. 7825, p. 357–362, 2020.
- HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The elements of statistical learning: data mining, inference, and prediction*. 2. ed. New York: Springer, 2009.

- JESUS, J. A. de; GUSMÃO, R. P. de. Investigação da evasão estudantil por meio da mineração de dados e aprendizagem de máquina: um mapeamento sistemático. *Revista Brasileira de Informática na Educação*, v. 32, p. 807–841, 2024.
- LUNDBERG, S. M.; LEE, S. I. A unified approach to interpreting model predictions. In: *ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS*, 30., 2017, Long Beach. Anais [...]. Red Hook: Curran Associates, 2017. p. 4765–4774.
- McKINNEY, W. Data structures for statistical computing in Python. In: *PYTHON IN SCIENCE CONFERENCE*, 9., 2010, Austin. Proceedings [...]. [S. l.]: SciPy, 2010. p. 56–61.
- NASCIMENTO, F. F. do; DANTAS, L. C. de O.; CASTRO, A. F. de; QUEIROZ, P. G. G. Técnicas de mineração de dados e aprendizado de máquina aplicados à evasão estudantil: um mapeamento sistemático da literatura. *Revista Brasileira de Informática na Educação*, v. 32, p. 270–294, 2024.
- PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.
- RIBEIRO, M. T.; SINGH, S.; GUESTRIN, C. “Why should I trust you?”: explaining the predictions of any classifier. In: *PROCEEDINGS OF THE 22ND ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING*, 2016, São Francisco. Anais [...]. New York: ACM, 2016. p. 1135–1144.
- ROBERTS, D. R. et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, v. 40, n. 8, p. 913–929, 2017.
- ROSA, L. et al. The effects of public high school subsidies on student test scores: the case of a full-day high school in Pernambuco, Brazil. *Economics of Education Review*, v. 87, art. 102201, 2022.
- SCULLEY, D. et al. Hidden technical debt in machine learning systems. In: *ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS*, 28., 2015, Montreal. Anais [...]. Red Hook: Curran Associates, 2015. p. 2503–2511.
- TEODORO, L. de A.; KAPPEL, M. A. A. Aplicação de técnicas de aprendizado de máquina para predição de risco de evasão escolar em instituições públicas de ensino superior no Brasil. *Revista Brasileira de Informática na Educação*, v. 28, p. 838–863, 2020.

APÊNDICE A – RELAÇÃO DAS 39 CARACTERÍSTICAS USADAS PELO SISTEMA

As características estão agrupadas pelos mesmos seis blocos apresentados no Capítulo 3. Os nomes entre parênteses são os identificadores usados no código e nos arquivos de dados, mantidos para permitir a auditoria dos resultados.

Contexto e localização (4)

- Localização rural (is_rural)
- Localização diferenciada, indígena ou quilombola (is_loc_diferenciada)
- Região do estado (CO_MESORREGIAO)
- Oferta de Ensino Médio fora das séries regulares, em educação de jovens e adultos ou organização modular (oferta_em_nao_seriado)

Porte e proporções (5)

- Porte, em número de matrículas (log_mat_med)
- Alunos por turma (alunos_por_turma)
- Alunos por professor (alunos_por_docente)
- Computadores por aluno (computadores_por_aluno)
- Proporção de matrículas em tempo integral (pct_integral)

Infraestrutura (13)

- Água potável (IN_AGUA_POTAVEL)
- Esgoto em rede pública (IN_ESGOTO_REDE_PUBLICA)
- Biblioteca (IN_BIBLIOTECA)
- Laboratório de ciências (IN_LABORATORIO_CIENCIAS)
- Laboratório de informática (IN_LABORATORIO_INFORMATICA)
- Quadra de esportes (IN_QUADRA_ESPORTES)
- Refeitório (IN_REFEITORIO)
- Sala de leitura (IN_SALA_LEITURA)
- Auditório (IN_AUDITORIO)
- Internet (IN_INTERNET)
- Internet para alunos (IN_INTERNET_ALUNOS)
- Banda larga (IN_BANDA_LARGA)
- Índice de infraestrutura (indice_infra)

Corpo docente (4)

- Regularidade do corpo docente (ird_med_t)
- Adequação da formação docente — grupo 1 (afd_g1_t)
- Adequação da formação docente — grupo 3 (afd_g3_t)

– Adequação da formação docente — grupo 5 (afd_g5_t)

Perfil dos alunos (5)

– Nível socioeconômico da escola (inse_media)

– Defasagem idade-série no Ensino Médio (tdi_med_t)

– Defasagem idade-série — 1ª série (tdi_s1_t)

– Defasagem idade-série — 2ª série (tdi_s2_t)

– Defasagem idade-série — 3ª série (tdi_s3_t)

Histórico de rendimento (8)

– Abandono no ano corrente (abnd_t)

– Abandono — 1ª série (abnd_s1_t)

– Abandono — 2ª série (abnd_s2_t)

– Abandono — 3ª série (abnd_s3_t)

– Reprovação no ano corrente (reprov_t)

– Reprovação — 1ª série (reprov_s1_t)

– Reprovação — 2ª série (reprov_s2_t)

– Reprovação — 3ª série (reprov_s3_t)